DICCIONARIO DE DATOS

Análisis de patrones de cobertura periodística en el diario La República

Archivo: data/noticias_larepublica_final.csv · 1116 registros · 18 variables

Unidad de observación: noticia. Identificador operativo: URL normalizada. El conjunto final no contiene valores nulos. La clasificación de secciones se infiere del primer segmento de la URL y no debe confundirse con las etiquetas temáticas.

Variable	Descripción	Tipo	Tamaño máximo	Valores	Unidad
tag	Etiqueta temática asociada a la noticia.	Categórico	48	Etiqueta del portal; Sin etiqueta	—
titulo	Titular completo de la noticia.	Texto	191	Texto libre	—
longitud_titulo	Longitud del texto del titular normalizado.	Numérico entero	3	33–191	Caracteres
url	Enlace de origen e identificador del registro.	Texto	273	https://larepublica.pe/...	—
autor	Firma del artículo registrada por el portal.	Categórico	25	121 nombres diferentes	—
hora	Hora asociada a la publicación.	Hora	5	00:00–23:59 (HH:MM)	Horas y minutos
fecha	Fecha de publicación registrada.	Fecha	10	2022-10-31–2026-09-22	AAAA-MM-DD
seccion	Área del portal obtenida de la ruta URL.	Categórico	18	28 secciones	—
anio	Año extraído de fecha.	Numérico entero	4	2022–2026	Años
mes	Número de mes extraído de fecha.	Numérico entero	2	1–12	Meses
anio_mes	Año y mes juntos para agrupación.	Texto	7	AAAA-MM	—
dia_semana	Día de la semana de fecha.	Categórico	9	Lunes–Domingo	—
hora_num	Hora entera obtenida de hora.	Numérico entero	2	0–23	Horas
franja_horaria	Tramo del día según hora_num.	Categórico	17	Madrugada, Mañana, Tarde, Noche	—
fin_de_semana	Marca de fecha en sábado o domingo.	Booleano	5	True / False	—
palabras_titulo	Cantidad de palabras separadas por espacios.	Numérico entero	2	5–32	Palabras

Variable	Descripción	Tipo	Tamaño máximo	Valores	Unidad
contiene_pregunta	Presencia de signo de interrogación en titular.	Booleano	5	True / False	—
contiene_cifra	Presencia de al menos un dígito en titular.	Booleano	5	True / False	—

Reglas de tratamiento

- Se conserva una fila por URL. Los títulos se normalizan en Unicode NFC y se homogeneizan los espacios.
- Cuando el campo tag está ausente se asigna el literal «Sin etiqueta», sin imputar un tema.
- La longitud del titular se calcula a partir de titulo. Se mantienen los valores extremos observados.
- La fecha codificada en la URL sirve únicamente como control y no reemplaza la fecha de publicación.
- Las variables binarias indican presencia o ausencia de rasgos explícitos, no una clasificación semántica.
- La fuente no contiene el cuerpo del artículo, audiencia, enlaces salientes ni datos de actualización.