UTEC
UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

Análisis de patrones de cobertura periodística

Diario La República · DS3021 Análisis Computacional de Datos

Aguirre Milla · Toribio Arrieta · Hurtado Vite · Pacheco Vera · Romano Castro

UTEC · 2026

Una pregunta, una colección concreta

¿Qué patrones aparecen en los temas, autores, horarios y titulares de las noticias recopiladas?

1 116

Noticias disponibles

2022–2026

Fechas registradas

No aleatoria

Selección de rutas

Las conclusiones describen la colección y no todas las publicaciones del diario.

Qué buscamos responder

- ¿Qué secciones y etiquetas predominan dentro de los registros?
- ¿Qué autores concentran más noticias y en qué secciones?
- ¿Cómo se distribuyen las horas y los días de publicación registrados?
- ¿Qué características diferencian a los titulares?
- ¿Cómo dejar los resultados verificables y reproducibles?

Una base analítica trazable

1 116

Filas del CSV final

18

Variables disponibles

0

Nulos en el CSV final

28

Secciones derivadas

Estructura original

tag, titulo, longitud_titulo, url, autor, hora, fecha

Información añadida

Secciones, componentes temporales, palabras y rasgos del titular.

Unidad de observación: una noticia identificada por su URL.

Pipeline de preparación

01

Ingreso

CSV original

02

Limpieza

Claves, nulos, texto

03

Integración

Metadatos URL

04

Derivación

Variables analíticas

05

Salida

CSV, JSON y figuras

Reproducción sin scraping

La ejecución utiliza un CSV fijo, por lo que una modificación futura del portal no altera los resultados guardados.

Control de calidad y decisiones

10	31	428	40
Etiquetas sin dato	Longitudes ajustadas	Fechas URL distintas	Atípicos IQR

- Las etiquetas vacías se identifican como «Sin etiqueta».
- Se recalcula la longitud con el texto realmente almacenado.
- La fecha de la URL no reemplaza la fecha de publicación.
- Los titulares atípicos se conservan si son registros válidos.

Once variables para investigar mejor

Sección (1)

Se obtiene del primer segmento del enlace y se usa como agrupación editorial.

Tiempo (7)

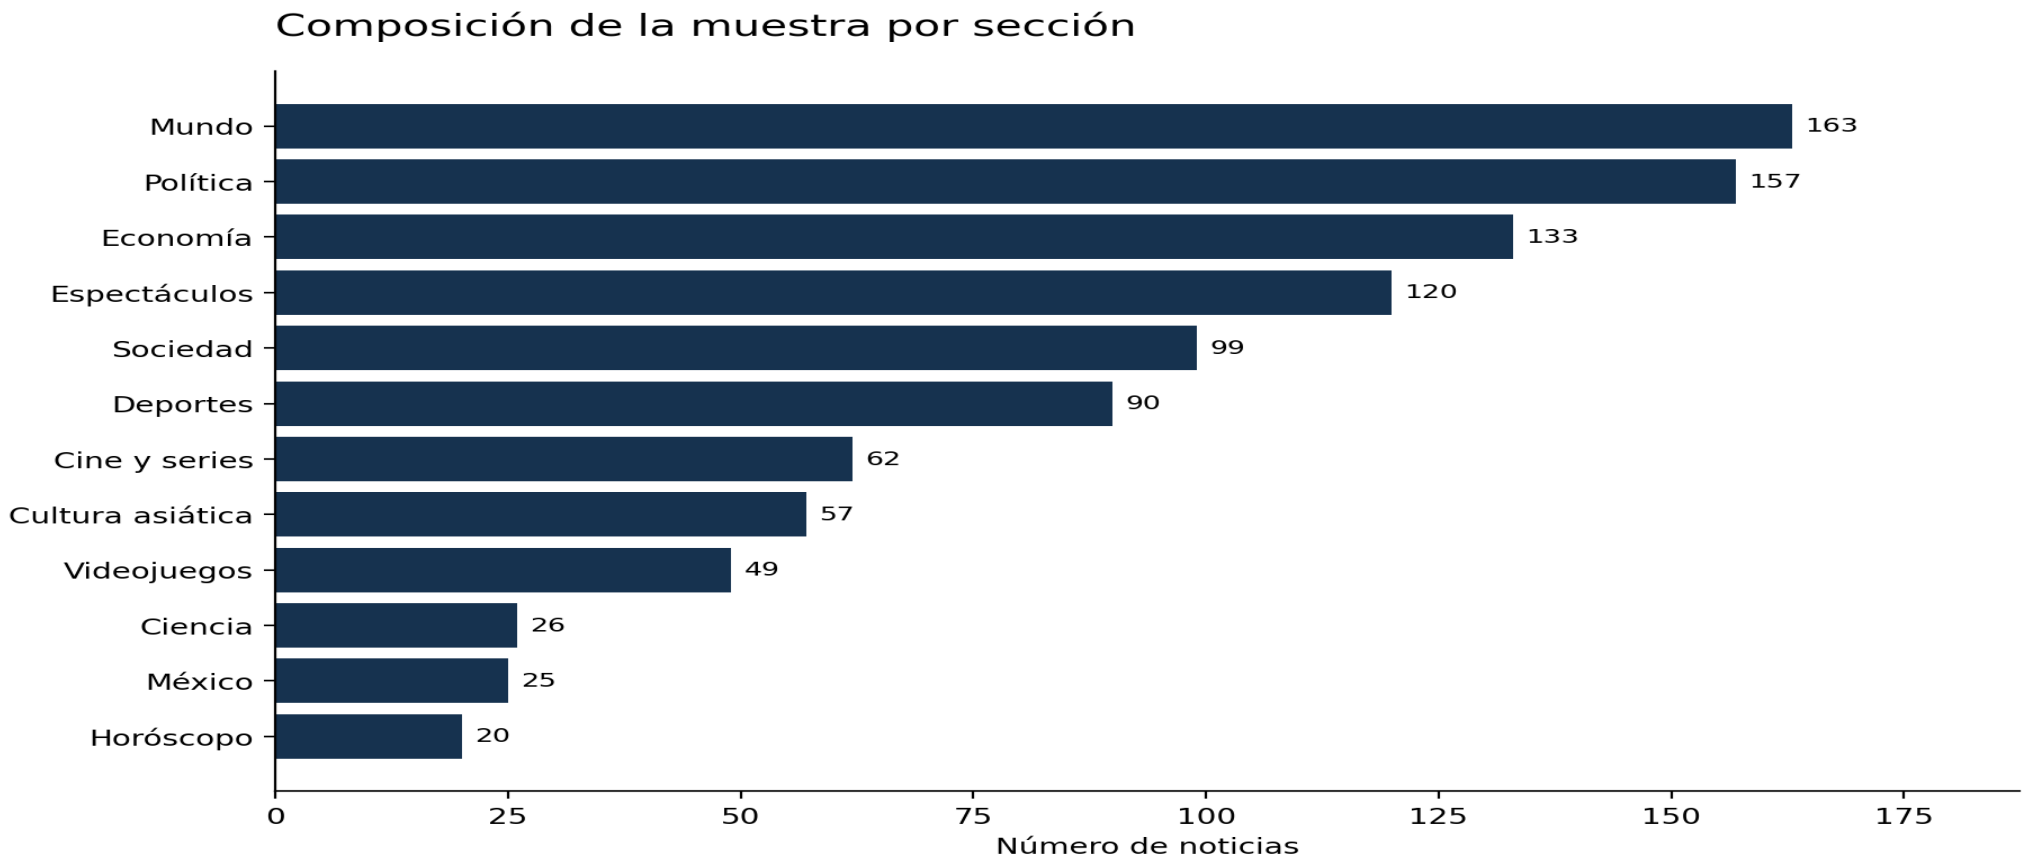
Año, mes, año-mes, día de semana, hora numérica, franja y fin de semana.

Titular (3)

Número de palabras, presencia de pregunta y presencia de cifra.

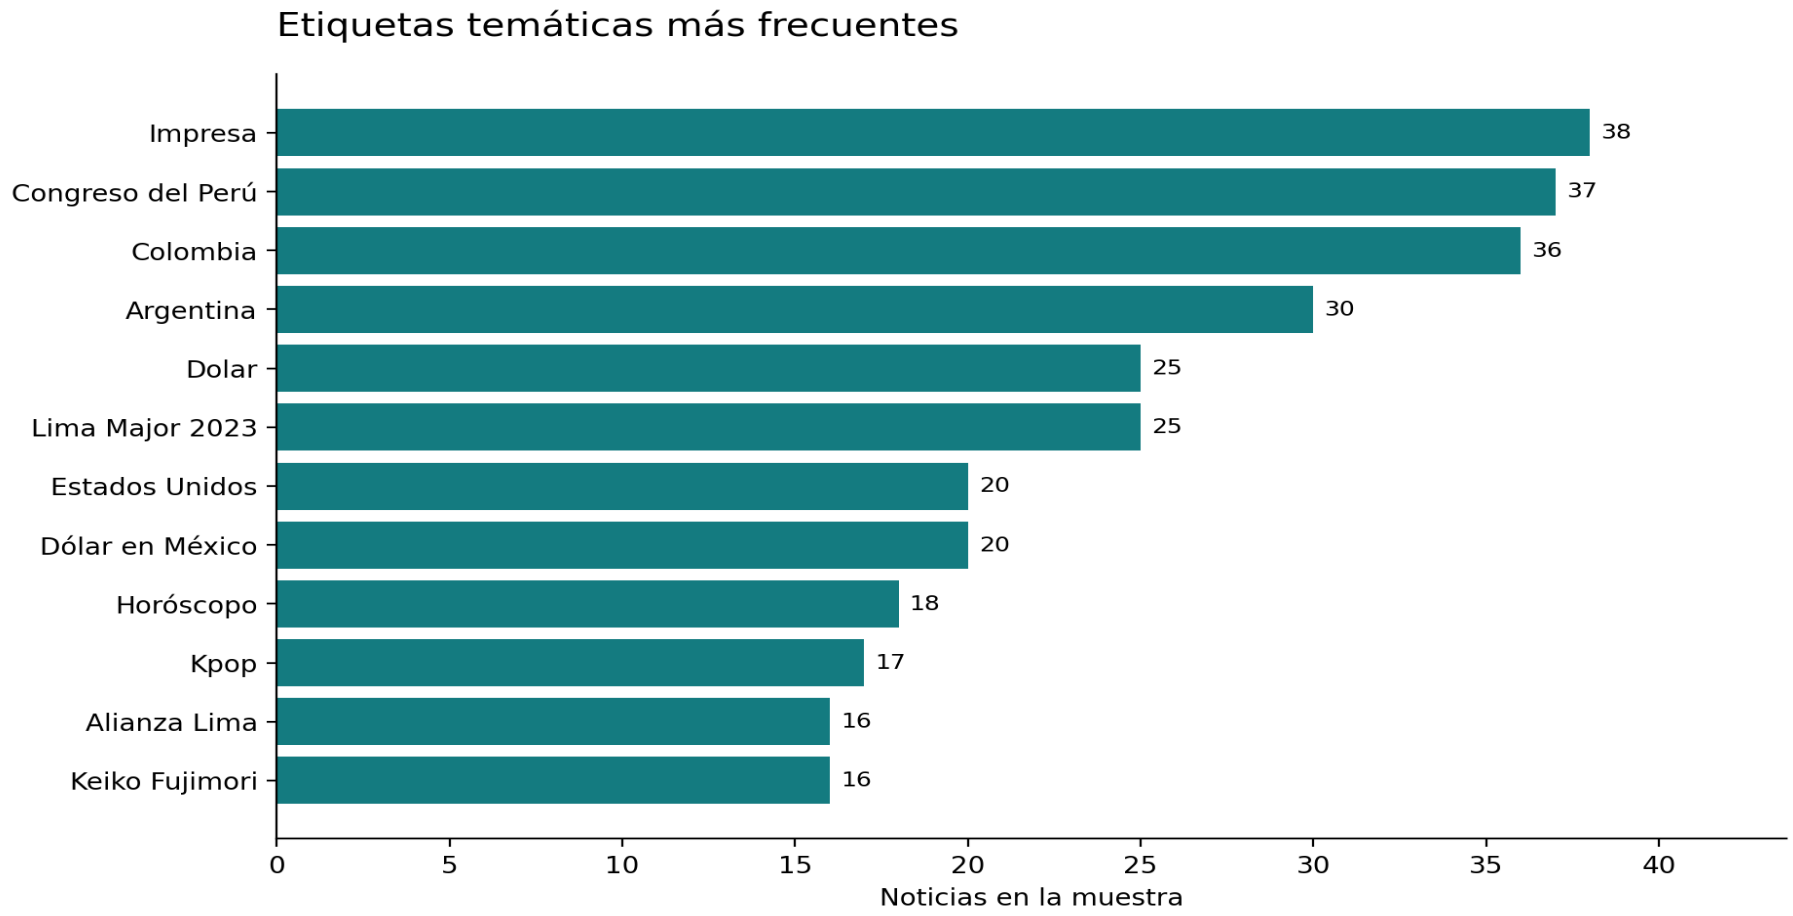
Sección y etiqueta temática responden a niveles de clasificación diferentes.

Distribución por sección



Las seis secciones principales reúnen el 68,28% de los registros.

Etiquetas: mucha diversidad, poca frecuencia



251 etiquetas

Aparecen una sola vez. Conviene comparar secciones para panoramas generales y conservar tags para temas específicos.

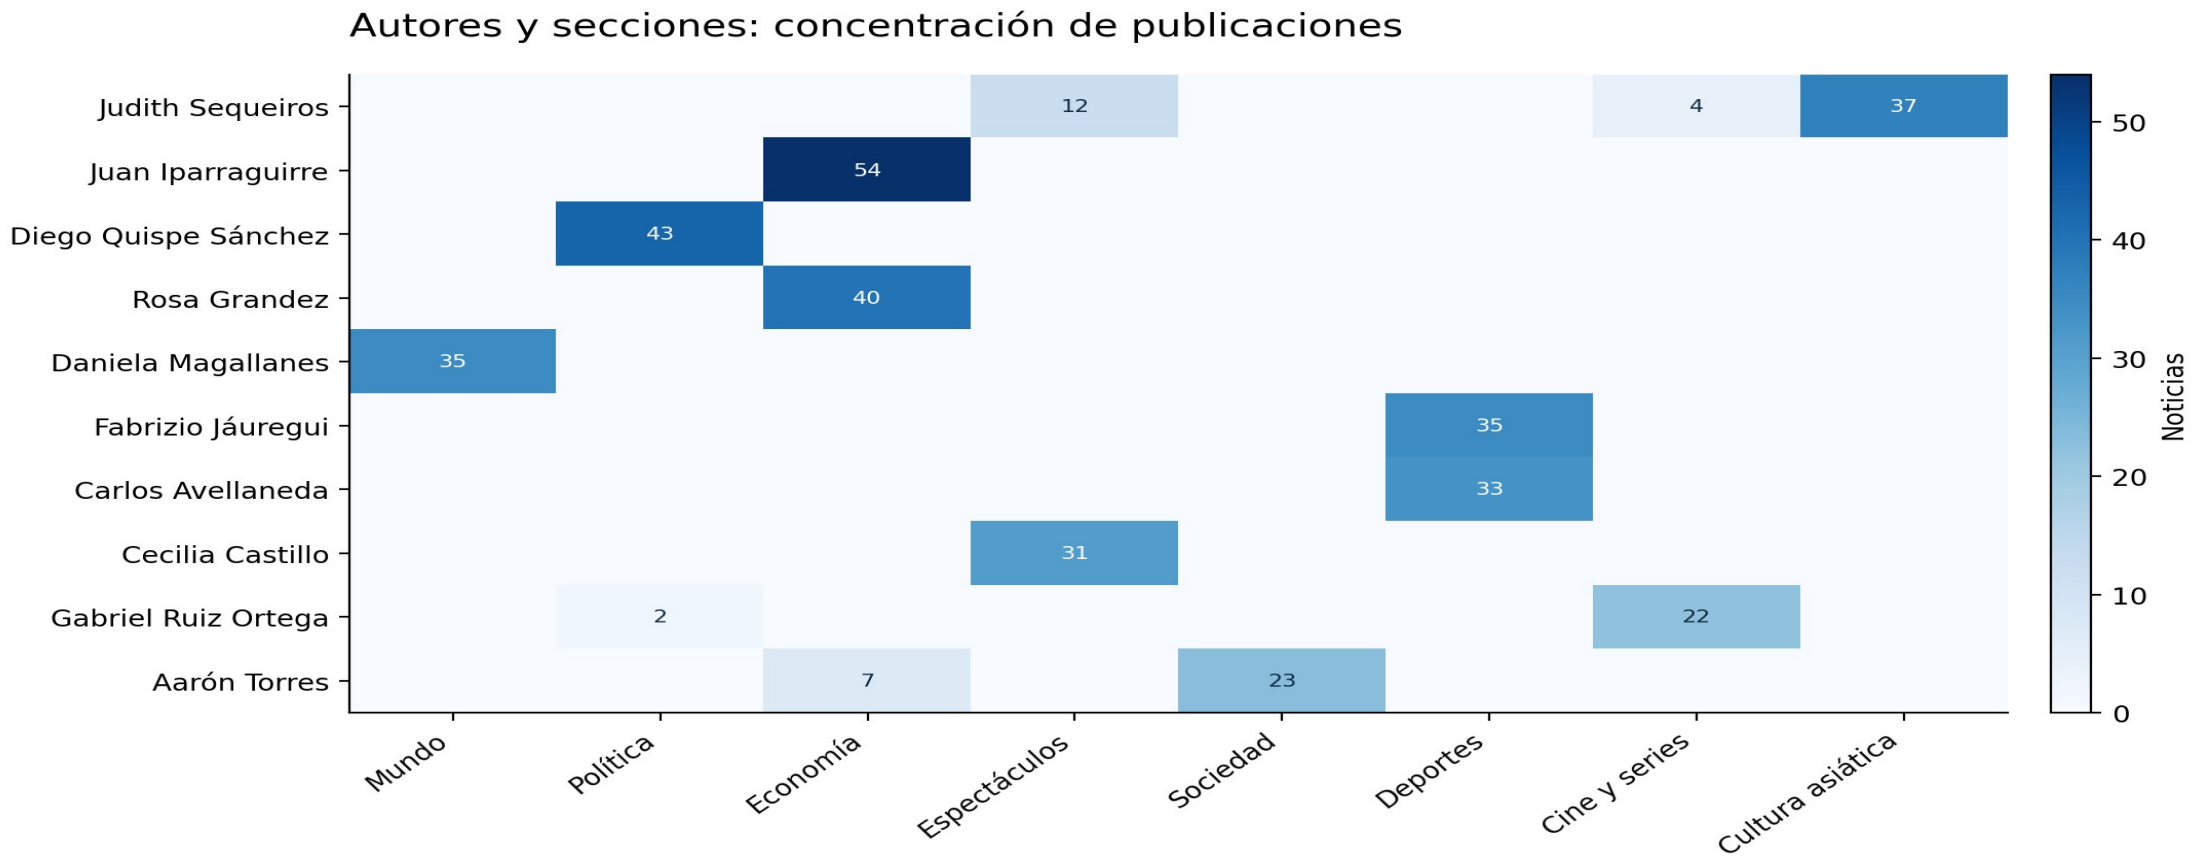
Distribución por autor



35,7 %

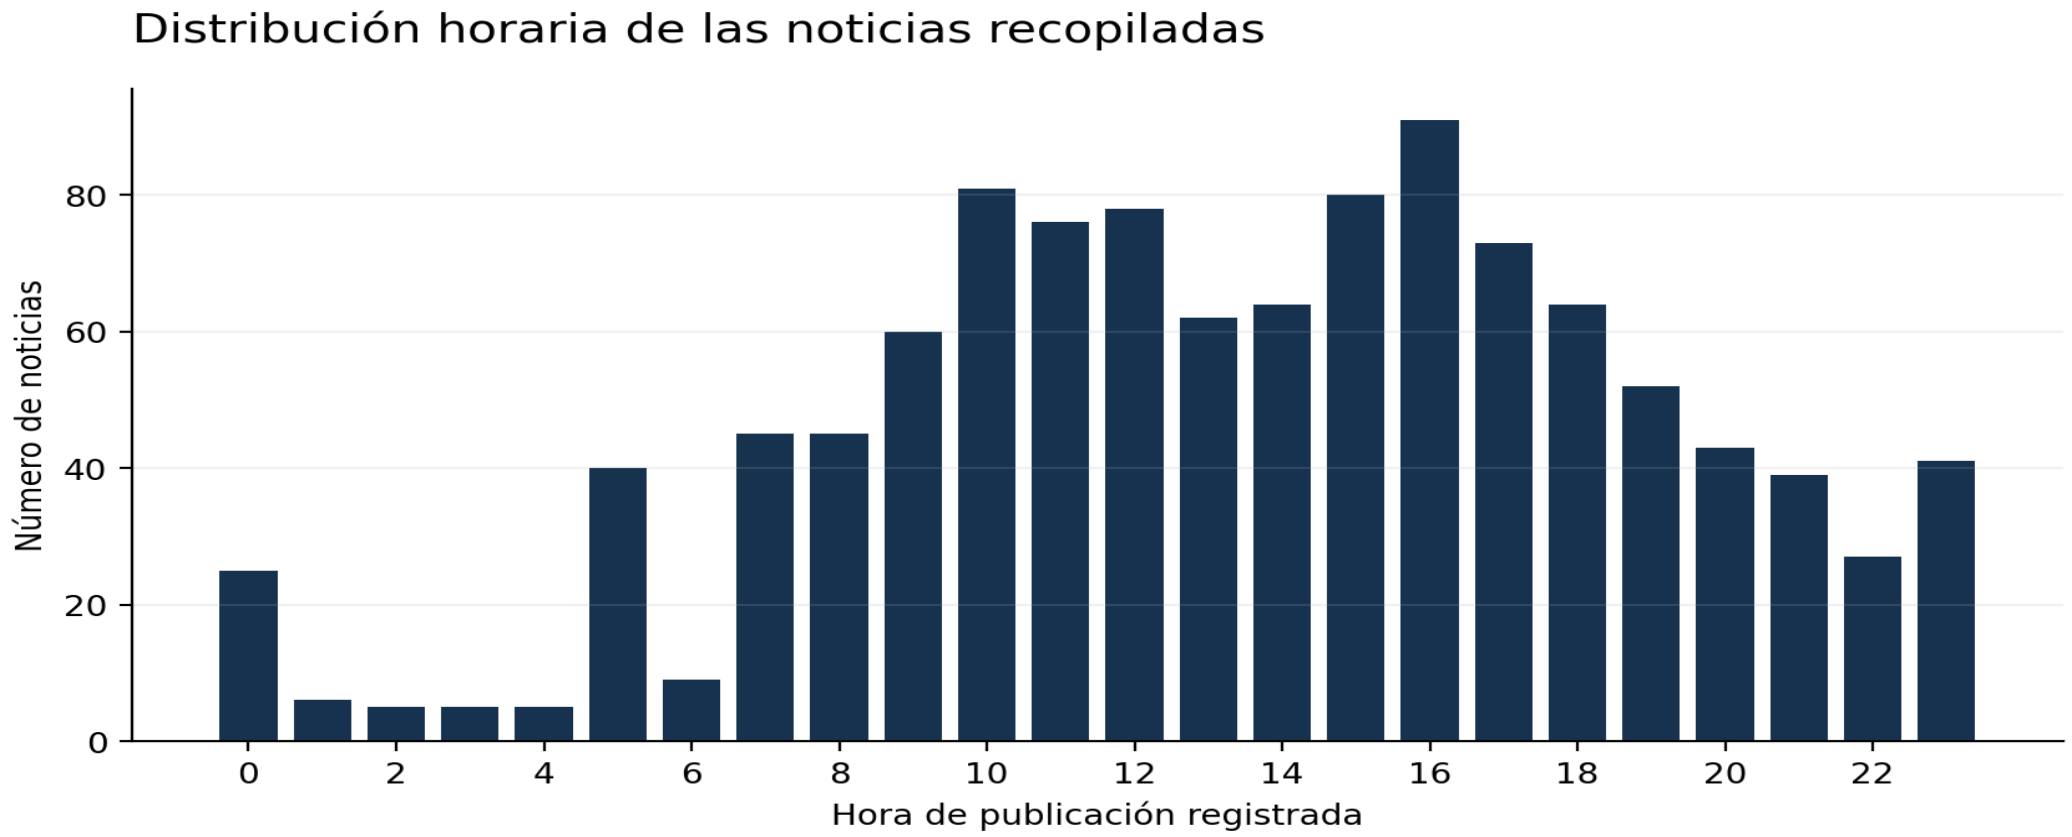
Es la participación conjunta de los diez autores con más noticias en la muestra.

Autores y secciones no se distribuyen igual



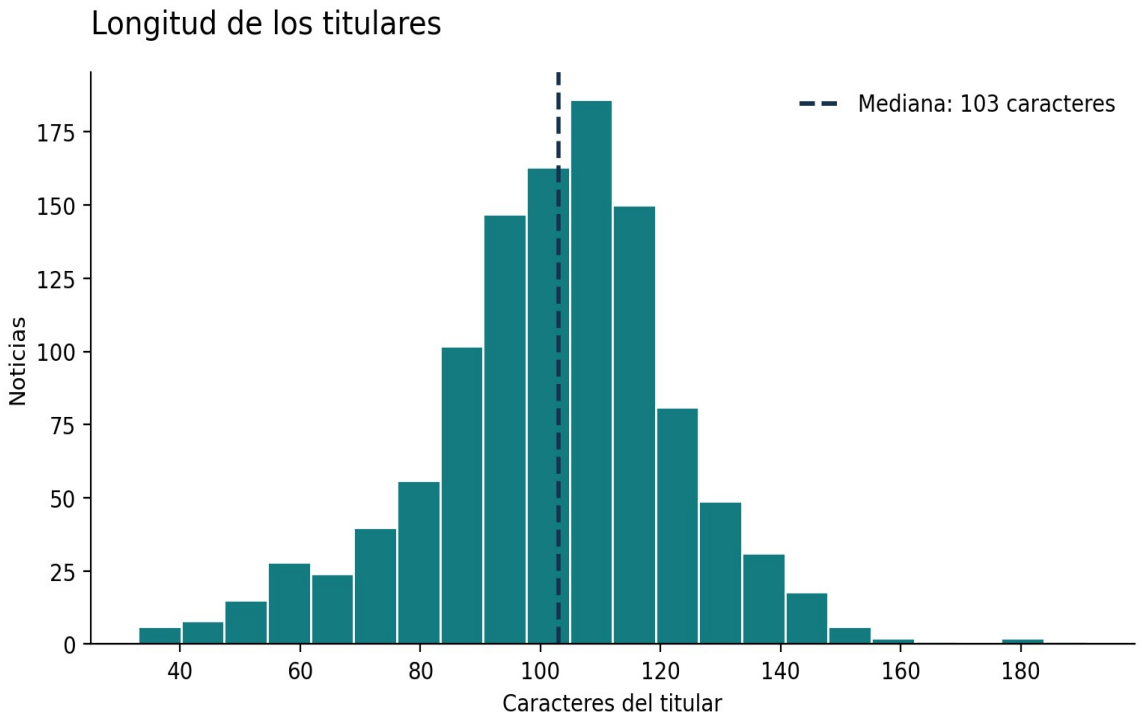
La concentración por firma puede reflejar especialización temática o las rutas consultadas.

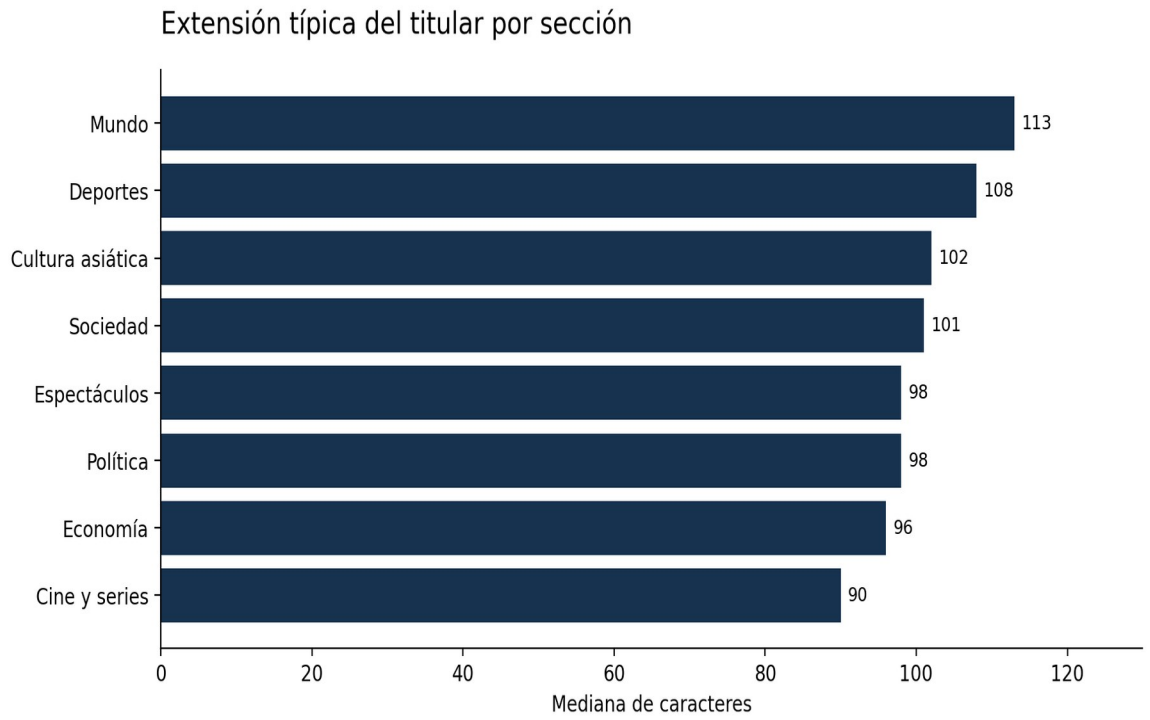
¿A qué horas aparecen las noticias?



Tarde (12:00–17:59): 448 noticias (40,1 %). El horario observado no equivale a la agenda completa del medio.

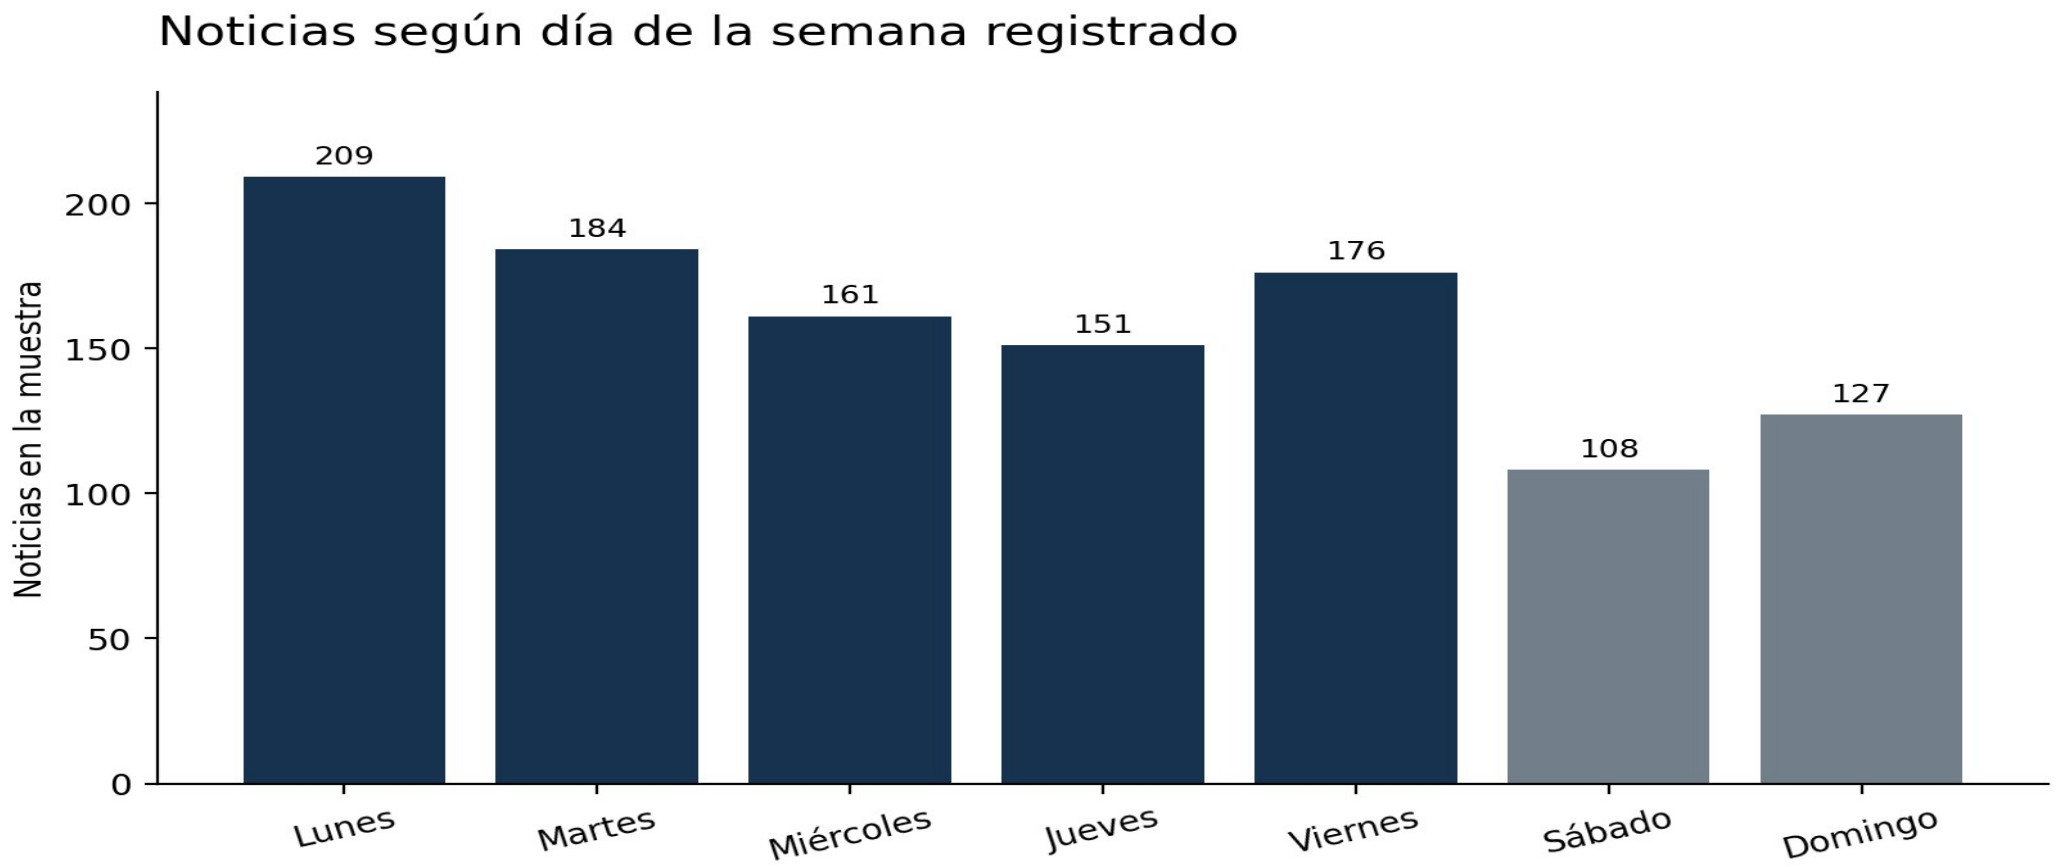
Titulares: extensión y diferencias





Mediana: 103 caracteres. El 48,8 % contiene al menos una cifra.

Días registrados: interpretación prudente



209 noticias fechadas en lunes frente a 108 en sábado.

No se puede inferir un ritmo semanal del diario sin una recolección continua y equilibrada.

Del hallazgo a la recomendación

Composición desigual

Reportar la cobertura de rutas junto con cualquier comparación de secciones.

Etiquetas muy específicas

Diferenciar la clasificación general de los temas puntuales.

Concentración por firma

Explorar la matriz autor × sección, sin interpretarla como productividad.

Fechas distintas en URL

Confirmar metadatos antes de realizar análisis históricos.

Conclusiones y reproducción

- La base final conserva 1 116 noticias y 18 variables.
- Se observan patrones por sección, autor, franja y estructura del titular.
- Los resultados describen la muestra y requieren prudencia para generalizar.
- El proyecto puede regenerar CSV, indicadores y gráficos desde un archivo fijo.

pip install -r requirements.txt · ejecutar notebooks 01 y 02 en Jupyter

Gracias